

Aritmética de ponto flutuante



UNIFEI

Universidade Federal de Itajubá

IMC – Instituto de Matemática e Computação

Prof. Carlos Minoru Tamaki

Princípios do ponto flutuante

- Deve separar faixa de precisão
- Usar notação científica $n = f \times 10^e$
 - f é a fração ou mantissa
 - e é o expoente (um número positivo ou negativo)
- Exemplos
 - $3.14 = 0.314 \times 10^1 = 3.14 \times 10^0$
 - $0.000001 = 0.1 \times 10^{-5} = 1.0 \times 10^{-6}$
 - $1941 = 0.1941 \times 10^4 = 1.941 \times 10^3$

- Sete regiões da linha dos números reais
 - Números negativos grandes menores que -0.999×10^{99} .
 - Números negativos entre -0.999×10^{99} and -0.100×10^{-99} .
 - Números negativos pequenos com grandezas menores que 0.100×10^{-99} .
 - Zero.
 - Números positivos pequenos com grandezas menores que 0.100×10^{-99} .
 - Números positivos entre 0.100×10^{-99} e 0.999×10^{99} .
 - Números positivos grandes maiores que 0.999×10^{99} .

A linha de números reais
pode ser dividida em sete
regiões.



Os limites inferior e superior aproximados de números decimais de ponto flutuante (não-normalizados) que podem ser expressos.

Dígitos na mantissa	Dígitos no expoente	Limite inferior	Limite superior
3	1	$1 \cdot 10^{-12}$	10^9
3	2	10^{-102}	10^{99}
3	3	10^{-1002}	10^{999}
3	4	10^{-10002}	10^{9999}
4	1	10^{-13}	10^9
4	2	10^{-103}	10^{99}
4	3	10^{-1003}	10^{999}
4	4	10^{-10003}	10^{9999}
5	1	10^{-14}	10^9
5	2	10^{-104}	10^{99}
5	3	10^{-1004}	10^{999}
5	4	10^{-10004}	10^{9999}
10	3	10^{-1009}	10^{999}
20	3	10^{-1019}	10^{999}

Padrão de ponto flutuante IEEE 754

Exemplos de números de ponto flutuante normalizados.

Exemplo 1: Exponenciação com base 2

Não-normalizado: $0 \ 1010100 \ 00000000000000011011$

Sinal: 0
Expoente: 1010100 (excesso é 64)
é $84 - 64 = 20$

Mantissa é $1 \times 2^{-12} + 1 \times 2^{-13} + 1 \times 2^{-15} + 1 \times 2^{-16}$

$= 2^{20} (1 \times 2^{-12} + 1 \times 2^{-13} + 1 \times 2^{-15} + 1 \times 2^{-16}) = 432$

Para normalizar, desloque a mantissa 11 bits para a esquerda e subtraia 11 do expoente.

Normalizado: $0 \ 1001001 \ 11011000000000000000$

Sinal: 0
Expoente: 1001001 (excesso 64)
é $73 - 64 = 9$

Mantissa é $1 \times 2^{-1} + 1 \times 2^{-2} + 1 \times 2^{-4} + 1 \times 2^{-5}$

$= 2^9 (1 \times 2^{-1} + 1 \times 2^{-2} + 1 \times 2^{-4} + 1 \times 2^{-5}) = 432$

Exemplos de números de ponto flutuante normalizados.

Exemplo 2: Exponenciação com base 16

Não-normalizado: $0 \ 1000101 \cdot \overset{16^{-1}}{\underset{00\ 00}{\triangle}} \overset{16^{-2}}{\underset{00\ 00}{\triangle}} \overset{16^{-3}}{\underset{00\ 01}{\triangle}} \overset{16^{-4}}{\underset{10\ 11}{\triangle}} = 16^5 (1 \times 16^{-3} + B \times 16^{-4}) = 432$

Sinal Expoente
+ em excesso
é $69 - 64 = 5$

Mantissa é $1 \times 16^{-3} + B \times 16^{-4}$


Para normalizar, desloque a mantissa 2 dígitos hexadecimais para a esquerda e subtraia 2 do expoente.

Normalizado: $0 \ 1000011 \cdot \overset{16^{-1}}{\underset{00\ 01}{\triangle}} \overset{16^{-2}}{\underset{10\ 11}{\triangle}} \overset{16^{-3}}{\underset{00\ 00}{\triangle}} \overset{16^{-4}}{\underset{00\ 00}{\triangle}} = 16^3 (1 \times 16^{-1} + B \times 16^{-2}) = 432$

Sinal Expoente
+ em excesso
64 é $67 - 64 = 3$

Mantissa é $1 \times 16^{-1} + B \times 16^{-2}$

Formatos de ponto flutuante
padrão IEEE. (a) Precisão
simples. (b) Precisão dupla.



(a)



(b)

Características dos números de ponto flutuante padrão IEEE.

Item	Precisão simples	Precisão dupla
Bits de sinal	1	1
Bits de expoente	8	11
Bits na mantissa	23	52
Bits, total	32	64
Sistema de expoente	Excesso 127	Excesso 1023
Faixa de expoente	-126 a +127	-1022 a +1023
Menor número normalizado	2^{-126}	2^{-1022}
Maior número normalizado	aprox. 2^{128}	aprox. 2^{1024}
Faixa decimal	aprox. 10^{-38} a 10^{38}	aprox. 10^{-308} a 10^{308}
Menor número desnormalizado	aprox. 10^{-45}	aprox. 10^{-324}

Tipos numéricos padrão IEEE.

Normalizado	$\pm$	$0 < \text{Exp} < \text{Max}$	Qualquer padrão de bits
Desnormalizado	$\pm$	0	Qualquer padrão de bits não-zero
Zero	$\pm$	0	0
Infinito	$\pm$	1 1 1...1	0
Não é um número	$\pm$	1 1 1...1	Qualquer padrão de bits não-zero


↖ Bit de sinal

Exemplo de conversão de números em ponto flutuante IEEE 754

- Converter o valor 13.8125 para binário

Parte inteira 13, divisões sucessivas:


$13/2 = 6$ resto 1
 $6/2 = 3$ resto 0
 $3/2 = 1$ resto 1
 $1/2 = 0$ resto 1



$13 = 1101$

Parte fracionária 0.8125, multiplicações sucessivas:

$0.8125 \times 2 = 1.625$
 $0.625 \times 2 = 1.25$
 $0.25 \times 2 = 0.5$
 $0.5 \times 2 = 1.0$



$0.8125 = 1101$

- Portanto o número 13.8125 em binário é
 - 1101.1101_2
- Normalizando:
 - $1.1011101_2 * 2^3 = 1.1011101$ com expoente 1000_2
- Calculando o expoente em excesso 127
 - $3 + 127 = 130_{10} = 10000010_2$
- Aplicando no padrão IEEE 754
 - $0 \ 10000010 \ 101110100000000000000000$
- 0 – Sinal da mantissa 0 = positiva, 1 = negativa
- 10000010 – expoente em excesso de 127
- 110111010000000000000000 – mantissa

Figura 9.18 Formato típico de ponto flutuante de 32 bits



(a) Formato

$$\begin{aligned} 1.1010001 \times 2^{10100} &= 0 \ 10010011 \ 101000100000000000000000 = 1.6328125 \times 2^{20} \\ -1.1010001 \times 2^{10100} &= 1 \ 10010011 \ 101000100000000000000000 = -1.6328125 \times 2^{20} \\ 1.1010001 \times 2^{-10100} &= 0 \ 01101011 \ 101000100000000000000000 = 1.6328125 \times 2^{-20} \\ -1.1010001 \times 2^{-10100} &= 1 \ 01101011 \ 101000100000000000000000 = -1.6328125 \times 2^{-20} \end{aligned}$$

(b) Exemplos

Tabela 9.3 Parâmetros de formato IEEE 754

Parâmetro	Formato			
	Isolado	Estendido isolado	Duplo	Estendido duplo
Tamanho da palavra (bits)	32	≥ 43	64	≥ 79
Tamanho do expoente (bits)	8	≥ 11	11	≥ 15
Polarização do expoente	127	Não especificado	1023	Não especificado
Expoente máximo	127	≥ 1023	1023	≥ 16383
Exponente mínimo	-126	≤ -1022	-1022	≤ -16382
Intervalo numérico (base 10)	$10^{-38}, 10^{+38}$	Não especificado	$10^{-308}, 10^{+308}$	Não especificado
Tamanho do significando (bits)*	23	≥ 31	52	≥ 63
Número de expoentes	254	Não especificado	2046	Não especificado
Número de frações	2^{23}	Não especificado	2^{52}	Não especificado
Número de valores	$1,98 \times 2^{31}$	Não especificado	$1,99 \times 2^{63}$	Não especificado

* Não incluso o bit implícito.

Tabela 9.4 Interpretação dos números de ponto flutuante IEEE 754


	Precisão simples (32 bits)				Precisão dupla (64 bits)			
	Sinal	Expoente polarizado	Fração	Valor	Sinal	Expoente viesado	Fração	Valor
Zero positivo	0	0	0	0	0	0	0	0
Zero negativo	1	0	0	-0	1	0	0	-0
Mais infinito	0	255 (todos 1s)	0	∞	0	2047 (todos 1s)	0	∞
Menos infinito	1	255 (todos 1s)	0	$-\infty$	1	2047 (todos 1s)	0	$-\infty$
NaN silencioso	0 ou 1	255 (todos 1s)	$\neq 0$	NaN	0 ou 1	2047 (todos 1s)	$\neq 0$	NaN
Nan sinalização	0 ou 1	255 (todos 1s)	$\neq 0$	NaN	0 ou 1	2047 (todos 1s)	$\neq 0$	NaN
Diferente de zero normalizado positivo	0	$0 < e < 255$	f	$2^{e-127}(1.f)$	0	$0 < e < 2047$	f	$2^{e-1023}(1.f)$
Diferente de zero normalizado negativo	1	$0 < e < 255$	f	$-2^{e-127}(1.f)$	1	$0 < e < 2047$	f	$-2^{e-1023}(1.f)$
Desnormalizado positivo	0	0	$f \neq 0$	$2^{e-126}(0.f)$	0	0	$f \neq 0$	$2^{e-1022}(1.f)$
Desnormalizado negativo	1	0	$f \neq 0$	$-2^{e-126}(0.f)$	1	0	$f \neq 0$	$-2^{e-1022}(1.f)$

Operações de ponto flutuante

Tabela 9.5 Números e operações aritméticas de ponto flutuante

Números de ponto flutuante	Operações aritméticas
$X = X_S \times B^{X_E}$ $Y = Y_S \times B^{Y_E}$	$\left. \begin{aligned} X + Y &= (X_S \times B^{X_E - Y_E} + Y_S) \times B^{Y_E} \\ X - Y &= (X_S \times B^{X_E - Y_E} - Y_S) \times B^{Y_E} \end{aligned} \right\} X_E \leq Y_E$ $X \times Y = (X_S \times Y_S) \times B^{X_E + Y_E}$ $\frac{X}{Y} = \left(\frac{X_S}{Y_S} \right) \times B^{X_E - Y_E}$

Adição/Subtração



Exemplo no sistema decimal

- $7,625 \times 10^2 + 1,75 \times 10^1$
- Ajustar os expoentes
 - $7,625 \times 10^2 + 0,175 \times 10^2$
- Efetuando a adição
 - $7,800 \times 10^2$
- Ajustar o expoente se necessário e obtendo o resultado:
 - $7,800 \times 10^2$


Exemplo no sistema binário

- 0 10001000 0111 1101 0100 0000 0000 000 → 7.625×10^2
- 0 10000011 0001 1000 0000 0000 0000 000 → 1.75×10^1
- Separando sinal, expoente e mantissa
 - 0 10001000 0 0000 0001 0111 1101 0100 0000 0000 000
 - 0 10000011 0 0000 0001 0001 1000 0000 0000 0000 000
- Ajustando o expoente de menor valor deslocando a mantissa para direita em 1 bit
 - 0 10001000 0 0000 0001 0111 1101 0100 0000 0000 000
 - 0 10000100 0 0000 0000 1000 1100 0000 0000 0000 000
- Executando mais 4 deslocamentos para direita
 - 0 10001000 0 0000 0001 0111 1101 0100 0000 0000 000
 - 0 10001000 0 0000 0000 0000 1000 1100 0000 0000 000

- 0 10001000 0 0000 0001 0111 1101 0100 0000 0000 000
- 0 10001000 0 0000 0000 0000 1000 1100 0000 0000 000
- Agora podemos realiza a operação de adição
 - 0 10001000 0 0000 0001 1000 0110 0000 0000 0000 000
- Ajustando com arredondamentos e truncamentos se necessário e normalizando teremos como resultado
 - 0 10001000 1000 0110 0000 0000 0000 000 000 → 7.80×10^2


Multiplicação

Figura 9.23 Multiplicação de ponto flutuante ($Z \leftarrow X \times Y$)



Divisão

Figura 9.24 Divisão de ponto flutuante ($Z \leftarrow X/Y$)



Bit de guarda

Figura 9.25 O uso dos guardas de bit

$$\begin{aligned}x &= 1.000\dots00 \times 2^1 \\ \underline{-y} &= \underline{0.111\dots11} \times 2^1 \\ z &= 0.000\dots01 \times 2^1 \\ &= 1.000\dots00 \times 2^{-22}\end{aligned}$$

(a) Exemplo binário, sem bits de guarda

$$\begin{aligned}x &= .100000 \times 16^1 \\ \underline{-y} &= \underline{.0FFFFFF} \times 16^1 \\ z &= .000001 \times 16^1 \\ &= .100000 \times 16^{-4}\end{aligned}$$

(c) Exemplo hexadecimal, sem bits de guarda

$$\begin{aligned}x &= 1.000\dots00 \ 0000 \times 2^1 \\ \underline{-y} &= \underline{0.111\dots11 \ 1000} \times 2^1 \\ z &= 0.000\dots00 \ 1000 \times 2^1 \\ &= 1.000\dots00 \ 0000 \times 2^{-23}\end{aligned}$$

(b) Exemplo binário, com bits de guarda

$$\begin{aligned}x &= .100000 \ 00 \times 16^1 \\ \underline{-y} &= \underline{.0FFFFFF \ F0} \times 16^1 \\ z &= .000000 \ 10 \times 16^1 \\ &= .100000 \ 00 \times 16^{-5}\end{aligned}$$

(d) Exemplo hexadecimal, com bits de guarda


Operações de produzem NaN silencioso

Tabela 9.6 Operações que produzem um NaN silencioso


Operação	NaN silencioso produzido por
Qualquer	Qualquer operação em um NaN sinalizador
Adição ou subtração	Subtração de magnitude de infinitos: $(+\infty) + (-\infty)$ $(-\infty) + (+\infty)$ $(+\infty) - (+\infty)$ $(-\infty) - (-\infty)$
Multiplicação	$0 \times \infty$
Divisão	$\frac{0}{0}$ ou $\frac{\infty}{\infty}$
Resto	$x \text{ REM } 0$ ou $\infty \text{ REM } y$
Raiz quadrada	$\sqrt{x}$, onde $x < 0$

Números desnormalizados

Figura 9.26 O efeito de números desnormalizados do IEEE 754



(a) Formato de 32 bits sem números desnormalizados



(b) Formato de 32 bits com números desnormalizados

Bibliografia

- Arquitetura e Organização de Computadores – William Stalings – 8ª Edição – Prentice Hall -2010
- IEEE Standard 754 Floating Point Numbers
- Base Convert
- IEEE-754 Floating Point Converter