

Arquiteturas de computadores paralelos



UNIFEI


Universidade Federal de Itajubá

IMC – Instituto de Matemática e Computação

Prof. Carlos Minoru Tamaki

Multicomputadores de troca de mensagens

Multicomputador genérico.



Topologia de Rede

Várias topologias.
Os pontos negros
representam comutadores.
As CPUs e memórias não
são mostradas. (a) Estrela.
(b) Malha de interconexão
completa. (c) Árvore.
(d) Anel. (e) Grade.
(f) Toro duplo. (g) Cubo.
(h) Hipercubo 4D.



(a)




(b)



(e)



(f)




(c)



(d)




(g)



(h)

MPP - BlueGene

Chip de processador
sob especificação
BlueGene/L.



MPP - BlueGene

BlueGene/L.


(a) Chip.

(b) Cartão.

(c) Placa.


(d) Gabinete.

(e) Sistema.




Red Storm

Pacote de componentes
do Red Storm.



Red Storm

Sistema Red Storm visto
de cima.



Comparação entre o BlueGene/L e o Red Storm

Item	BlueGene/L	Red Storm
CPU	PowerPC de 32 bits	Opteron de 64 bits
Relógio	700 MHz	2 GHz
CPUs de cálculo	65.536	10.368
CPUs/placa	32	4
CPUs/gabinete	1.024	96
Gabinetes de cálculo	64	108
Teraflops/s	71	41
Memória/CPU	512 MB	2-4 GB
Memória total	32 TB	10 TB
Roteador	PowerPC	Seastar
Número de roteadores	65.536	10.368
Interconexão	Toros 3D de $64 \times 32 \times 32$	Toros 3D de $27 \times 16 \times 24$
Outras redes	Gigabit Ethernet	Fast Ethernet
Pode ser particionado?	Não	Sim
Sistema Operacional	Proprietário	Proprietário
SO de E/S	Linux	Linux
Fabricante	IBM	Cray Research
Caro?	Sim	Sim

Computação em cluster

- Consiste em centenas de milhares de PCs ou estações de trabalho conectadas por uma placa de rede
- A diferença entre MPP e um cluster é análoga à diferença entre um mainframe e um PC.
- Existem muitos tipos de clusters, mas há dois tipos que dominam: o centralizado e o descentralizado
- De modo geral, clusters são conjuntos pequenos, na faixa de uma dúzia a 500 PCs.

Google – 1º Servidor



Google – 1º Storage

Em 1996, Larry Page e Sergey Brin, dois estudantes da universidade de Stanford, trabalhavam num projeto de digitalização de biblioteca(Digital Library Project) e necessitavam de uma grande quantidade de armazenamento para testar seus algoritmos do Pagerank em dados da internet. Naquela época, os maiores HDs tinham apenas 4 GigaBytes de armazenamento, Page e Brin colocaram 10 HD's em um gabinete de baixo-custo criando um total de 40 GigaBytes de armazenamento.



Google – Servidor em 2001



Google




Google




Google

Processamento de uma consulta no Google.




Google

Cluster Google típico.




Computação em cluster - Microwulf

<https://sites.calvin.edu/adams/research/microwulf/>




Computação em cluster - Microwulf




Computação em cluster – Microwulf - Hardware

Component	Product	Unit Price	Quantity	Total
Motherboard	MSI K9N6PGM-F MicroATX	\$80.00	4	\$320.00
CPU	AMD Athlon 64 X2 3800+ AM2 CPU	\$165.00	4	\$660.00
Main Memory	Kingston DDR2-667 1GByte RAM	\$124.00	8	\$992.00
Power Supply	Echo Star 325W MicroATX Power Supply	\$19.00	4	\$76.00
Network Adaptor	Intel PRO/1000 PT PCI-Express NIC (node-to-switch)	\$41.00	4	\$164.00
Network Adaptor	Intel PRO/100 S PCI NIC (master-to-world)	\$15.00	1	\$15.00
Switch	Trendware TEG-S80TXE 8-port Gigabit Ethernet Switch	\$75.00	1	\$75.00
Hard drive	Seagate 7200 250GB SATA hard drive	\$92.00	1	\$92.00
DVD/CD drive	Liteon SHD-16S1S 16X	\$19.00	1	\$19.00
Cooling	Zalman ZM-F3 120mm Case Fans	\$8.00	4	\$32.00
Fan protective grills	Generic NET12 Fan Grill (120mm)	\$1.50 + shipping	4	\$10.00
Support Hardware	36" x 0.25" threaded rods	\$1.68	3	\$5.00
Fastener Hardware	Lots of 0.25" nuts and washers			\$10.00
Case/shell	12" x 11" polycarbonate pieces (scraps from our Physical Plant)	\$0.00	4	\$0.00
Total				\$2,470.00

Computação em cluster - Microwulf



Computação em cluster - Microwulf



Cluster PS3 da Unicamp



Sala da Unicamp tem 12 PlayStation 3 ligados em rede
(Foto: Gustavo Tilio/G1)

Software de comunicação para multicomputadores

- Programar um multicomputador requer software especial, usualmente bibliotecas, para manipular a comunicação e sincronização entre processos.
- Os sistemas de troca de mensagens fornecem 2 primitivas: send e receive e as três variantes principais são:
 - Troca síncrona de mensagens
 - Troca de mensagens por buffer
 - Troca de mensagens sem bloqueio


Software de comunicação para multicomputadores

- Durante muitos anos, o pacote de comunicação mais popular para multicomputadores foi a PVM (Parallel Virtual Machine)
- Atualmente outro pacote está substituindo o PVM que é o MPI (Message-Passing Interface) que é muito mais rica e mais complexa, possui muito mais chamadas de biblioteca, mais opções e mais parâmetros de chamada.
- MPI-2 amplia o MPI-1 em 1997, com recursos de processos dinâmicos, acesso à memória remota, comunicação coletiva sem bloqueio, suporte para E/S escalável, processamento em tempo real e muitas outras características.

Escalonamento

Escalonamento de um cluster. (a) FIFO. (b) Sem bloqueio de cabeça de fila. (c) Lajotas. As áreas sombreadas indicam CPUs ociosas.

Os programadores de MPI podem criar jobs com facilidade requisitando várias CPUs e executando durante períodos substanciais de tempo.




Memória compartilhada distribuída DSM – Distributed Shared Memory

Espaço de endereço virtual que consiste em 16 páginas distribuídas por quatro nós de um multicomputador.

(a) Situação inicial.

(b) Após a CPU 0 referenciar a página 10.

(c) Após a CPU 1 referenciar a página 10, neste caso considerando que ela é uma página somente de leitura.



Linda

- Esta é uma variação do sistema DSM baseado em páginas.
- Linda, fornece processos em várias máquinas com uma memória compartilhada distribuída com alto grau de estruturação. Essa memória é acessada por meio de um pequeno conjunto de operações primitivas que podem ser adicionadas a linguagens existentes, como C e Fortran, para formar linguagens paralelas C-Linda e Fortran-Linda.

Três tuplas Linda.

("abc", 2, 5)

("matrix-1", 1, 6, 3.14)

("família", "é irmã", Carolyn, Elinor)

Orca

Orca é uma linguagem de programação baseada em Modula 2, em que foram adicionadas novas características como: objetos e habilidade de criar novos processos.

Objeto pilha (stack) ORCA simplificado, com dados internos e duas operações.

Object implementation stack;

top:integer;

armazenamento para a pilha

stack: **array** [integer 0..N-1] **of** integer;

operação push(item: integer);

função retorna nada

begin

guard top < N - 1 **do**

 stack[top] := item;

passe item para a pilha

 top := top + 1;

incremente o ponteiro de pilha

od;

end;

operação pop(): integer;

função retornando um inteiro

begin

guard top > 0 **do**

suspenda se a pilha estiver vazia

 top := top - 1;

decmente o ponteiro de pilha

 return stack[top];

retorne o item do topo

od;

end;

begin

 top := 0;

inicialização

end;

Globe


- A maioria dos sistemas DSM, Linda e Orca executam em sistemas locais.
- No sistema Globe, um objeto pode estar localizado no espaço de endereço de vários processos ao mesmo tempo, possivelmente em diferentes continentes.
- O que torna o Globe um tanto ambicioso é sua meta de ser ampliado para um bilhão de usuários e um trilhão de objetos.

Desempenho

- Métrica de Hardware:
 - Da perspectiva do hardware, a métrica do desempenho que interessa são as velocidades de CPU e E/S e o desempenho da rede de interconexão.
- Métrica de Software:
 - Os usuários querem saber o ganho de rapidez na execução de um programa em um computador paralelo em vez de uniprocessador.

Métricas de software


Programas reais alcançam menos do que o aumento perfeito de velocidade indicado pela linha pontilhada.




Métricas de software

(a) Um programa tem uma parte seqüencial e uma parte que pode utilizar paralelismo.

(b) Efeito da execução de parte do programa em paralelo.



(a)



(b)


Obtenção de alto desempenho

(a) Sistema de 4 CPUs com um barramento.


(b) Sistema de 16 CPUs com um barramento.

(c) Sistema de 4 CPUs em grade.

(d) Sistema de 16 CPUs em grade.




(a)



(b)



(c)



(d)

Computação em grade

Camadas da grade.

Função	Camada
Aplicação	Aplicações que compartilham recursos gerenciados de modos controlados
Coletiva	Descoberta, corretagem, monitoração e controle de grupos de recursos
De recursos	Acesso seguro e gerenciado a recursos individuais
Base	Recursos físicos: computadores, armazenamento, redes, sensores, programas e dados

OGSA – Open Grade Services Architecture

OGSA – Open Grade Service Architecture

1. Serviços de infra-estrutura (habilitar comunicação entre recursos)
2. Serviços de gerenciamento de recursos (reserva e distribuição de recursos)
3. Serviços de dados (mover e replicar dados para onde forem necessários)
4. Serviços de contexto (descrever recursos requeridos e políticas de utilização)
5. Serviços de informação (obter informação sobre disponibilidade de recursos)
6. Serviços de auto gerenciamento (suportar uma qualidade de serviços declarada)
7. Serviços de segurança (impor políticas de segurança)
8. Serviços de gerenciamento de execução (gerenciar fluxo de trabalho)

Softwares e Bibliotecas

- **Processamento multinúcleos**
 - **OpenMP** (Open Multi-Processing) é um padrão de programação paralela para sistemas com memória compartilhada, amplamente utilizado em CPUs multicore. Ele permite paralelizar programas em C, C++ e Fortran usando directivas (pragmas) simples, sem modificar profundamente o código original.
- **Processamento multicomputadores (cluster)**
 - **MPI** (Message Passing Interface) é o padrão mais usado no mundo para programação paralela distribuída, especialmente em clusters de alto desempenho (HPC). Ele permite que vários processos — normalmente em diferentes máquinas — troquem mensagens entre si para resolver problemas grandes demais para um único computador.

Softwares e Bibliotecas

- **Processamento em GPU**

- **CUDA** (Compute Unified Device Architecture) é uma plataforma de computação paralela e modelo de programação desenvolvida pela NVIDIA que permite usar GPUs (Graphics Processing Units) para computação de propósito geral, conhecida como GPGPU (General-Purpose computing on Graphics Processing Units).
- **ROCm** (Radeon Open Compute) é a plataforma de computação de código aberto da AMD para computação de alto desempenho (HPC) e machine learning em GPUs AMD Radeon e Instinct. É o equivalente da AMD ao CUDA da NVIDIA.
- **OpenCL** (Open Computing Language) é um padrão aberto para programação paralela que permite aproveitar o poder de diferentes tipos de hardware em um mesmo sistema — como CPUs, GPUs, FPGAs e DSPs — usando uma única API e um único modelo de programação.
- **OpenACC** (Open Accelerators) é um padrão de programação baseado em diretivas (pragmas) que permite acelerar código em GPUs e outros aceleradores de forma mais simples que CUDA, sem necessidade de reescrever completamente o código.
- **SYCL** (pronounced "sickle") é um padrão de programação paralela moderno e de alto nível baseado em C++ puro (C++17/20) que permite escrever código heterogêneo (CPU, GPU, FPGA, aceleradores) de forma portátil, desenvolvido pelo Khronos Group (mesmo do OpenCL e Vulkan).

Comparação das tecnologias

Aspecto	SYCL	CUDA	OpenCL	OpenACC
Linguagem	C++ puro	C++ extensions	C99 + extensions	C/C++/Fortran + pragmas
Single-source	✓	✓	✗	✓
Portabilidade	Multi-vendor	NVIDIA	Multi-vendor	Multi-vendor
Verbosidade	Baixa	Média	Alta	Mínima
Performance	Excelente	Excelente	Boa	Boa
C++ moderno	✓ Templates, lambdas	Parcial	✗	N/A
Curva aprendizado	Moderada	Moderada	Alta	Baixa
Ecossistema	Crescendo	Maduro	Fragmentado	Limitado

Bibliografia

- Organização Estruturada de Computadores – Andrew S. Tanenbaum, Tood Austin – 6ª Edição 2013 Prentice Hall
- Vários sites da internet